

Predicción de Fuga de Clientes (Customer Churn)

Modelo predictivo con enfoque de negocio, validación estadística e interpretabilidad (SHAP)

Mauricio Felipe Bustillos Meneses · Ingeniero en Informática (Duoc UC) · Python · Scikit-learn · LightGBM · SHAP

1. Resumen Ejecutivo

Este proyecto desarrolla un modelo de machine learning para predecir la fuga de clientes (churn) en una empresa de telecomunicaciones, con el objetivo de habilitar campañas de retención proactivas antes de que el cliente cancele el servicio.

Se compararon cinco algoritmos de clasificación bajo un criterio explícito de negocio: minimizar los falsos negativos (clientes que se van sin ser detectados), incluso a costa de una menor precisión general. El modelo final (LightGBM) fue validado con cross-validation estratificada, optimizado mediante búsqueda de hiperparámetros, e interpretado con SHAP para traducir sus predicciones en recomendaciones accionables de negocio.

Resultado principal: el modelo base identifica correctamente el 76% de los clientes que efectivamente se fugan, con un ROC-AUC de 0.838 en validación cruzada — una base sólida para dirigir campañas de retención segmentadas.

2. Contexto y Objetivo de Negocio

Retener a un cliente existente es sistemáticamente más económico que adquirir uno nuevo. Por esto, el objetivo del modelo no es maximizar la exactitud general (Accuracy), sino maximizar la Sensibilidad (Recall): detectar la mayor cantidad posible de clientes en riesgo real de fuga, aceptando un número mayor de falsas alarmas como costo tolerable frente al costo de perder un cliente sin advertencia.

Dataset utilizado: "Telco Customer Churn" (fuente pública, Kaggle), con 7,043 registros de clientes, incluyendo variables demográficas, servicios contratados, información de facturación y la variable objetivo Churn (Sí/No).

3. Metodología

- **Limpieza de datos** — Limpieza y validación: tratamiento de nulos, duplicados, inconsistencias de formato y corrección de tipos de datos.
- **Preprocesamiento** — Codificación de variables categóricas (Label Encoding, One-Hot Encoding) y escalado numérico con MinMaxScaler.

- **Partición de datos** — División estratificada con semilla fija para asegurar reproducibilidad del pipeline.
- **Modelado** — Entrenamiento de 5 algoritmos con mitigación de desbalance de clases (`class_weight='balanced'` / `scale_pos_weight`).
- **Validación cruzada** — Cross-validation estratificada (5-Fold): Recall promedio de 74.96% ($\pm 2.33\%$), ROC-AUC promedio de 0.8379, confirmando que el resultado no depende de una partición particular de los datos.
- **Optimización de hiperparámetros** — RandomizedSearchCV sobre LightGBM, optimizando explícitamente por Recall.
- **Interpretabilidad** — Análisis SHAP para identificar qué variables impulsan cada predicción, más allá de la importancia agregada de variables.

4. Resultados: Comparación de Modelos

Se evaluaron cinco algoritmos bajo idénticas condiciones de validación:

Modelo	Accuracy	Precisión	Recall	ROC-AUC	Veredicto
Regresión Logística	74.04%	46.17%	80.69%	—	Máxima protección: mejor Recall entre modelos base.
Random Forest	77.39%	50.47%	67.29%	—	Alta precisión, pero deja escapar más fugas.
XGBoost	75.75%	47.92%	68.22%	—	Superado en sensibilidad por LR y LightGBM.
SVM	74.32%	46.38%	77.88%	—	Descartado: alto costo computacional, poca interpretabilidad.
LightGBM (Base)	76.60%	49.29%	76.01%	—	Mejor equilibrio velocidad / Recall entre modelos base.
LightGBM (Tuneado)	79.24%	53.75%	66.98%	0.849	Mejor Accuracy y ROC-AUC, pero Recall menor al base (ver Limitaciones).

Modelo recomendado para producción: LightGBM (Base). Aunque la versión tuneada mejora Accuracy y ROC-AUC, su Recall es menor — ver sección de Limitaciones para el detalle de esta decisión.

5. Hallazgos de Negocio

- **Fricción administrativa:** El modelo de suscripción "mes a mes" y el pago mediante cheque electrónico son los principales motores de fuga, frente a contratos de largo plazo con tarifas preferenciales.
- **Anclas de retención:** La tenencia de Soporte Técnico y Seguridad en línea actúa como una barrera clave contra la deserción; los hogares con múltiples integrantes muestran mayor lealtad que los usuarios individuales.

- **Hallazgo inesperado (SHAP):** El análisis SHAP reveló que tener fibra óptica (el servicio de mayor velocidad) se asocia con una mayor probabilidad de fuga — un hallazgo contraintuitivo que sugiere problemas de calidad de servicio o de percepción de precio en ese segmento, no un problema del servicio en sí.

6. Recomendaciones de Negocio

- **Segmentación de oferta:** Creación de Planes Familiares dinámicos según tamaño del hogar, y Planes Unipersonales de menor costo para evitar cancelaciones por percepción de "capacidad ociosa" pagada.
- **Migración digital:** Incentivos para migrar a los usuarios hacia pagos automáticos (tarjeta/débito directo), reduciendo la cancelación por fricción de cobro.
- **Revisión del segmento fibra óptica:** Investigar específicamente la experiencia de los clientes con fibra óptica, dado que el hallazgo de SHAP sugiere un problema de calidad o precio percibido no evidente en las métricas agregadas.

7. Limitaciones y Próximos Pasos

Trade-off del tuning: la búsqueda de hiperparámetros optimizó Accuracy, Precisión y ROC-AUC, pero el Recall del modelo tuneado (66.98%) quedó por debajo del modelo base (76.01%) — contrario al criterio de negocio priorizado en este proyecto. Por esto, el modelo recomendado para producción sigue siendo la versión base, salvo que se amplíe el espacio de búsqueda de hiperparámetros en una futura iteración.

- **Deployment:** Despliegue del modelo mediante una API REST (FastAPI) integrada a un CRM, para generar alertas de fuga en tiempo real.
- **Optimización avanzada:** Ampliar la búsqueda de hiperparámetros con Optuna, sin sacrificar Recall.
- **MLOps:** Monitoreo continuo del desempeño del modelo en producción para detectar degradación de datos (data drift).

8. Stack Tecnológico

- **Lenguaje:** Python 3.x
- **Manipulación de datos:** Pandas, NumPy
- **Modelado y métricas:** Scikit-learn, LightGBM, XGBoost
- **Interpretabilidad:** SHAP
- **Visualización:** Matplotlib, Seaborn

9. Enlaces

Repositorio completo (código, notebook y README):

<https://github.com/mauriciobustillosmeneses17-art/customer-churn-prediction>